北京航空航天大學

BEIHANG UNIVERSITY

生成式人工智能在反腐败宣传教育中的应用

——效果评估与法律伦理边界

作　　者：

何予晴 25379191

罗子砚 25371133

程铭　 25371387

宋博文 25373288

指导老师：吴桂德

生成式人工智能在反腐败宣传教育中的应用

——效果评估与法律伦理边界

摘要

生成式人工智能的快速发展为反腐败宣传教育提供了新的技术可能，但如何从“不敢腐”“不能腐”向“不想腐”深层延伸，仍是廉洁文化建设的核心难题。本研究旨在探索 AIGC 在廉政教育中的应用效果及其法律伦理边界，为新时代廉洁文化建设提供技术赋能与规制保障的双重支撑。

研究构建“技术赋能—效果评估—风险识别—边界规制”四维分析框架，综合运用实证研究与规范分析方法。实证部分采用 A/B 测试，以 100 名公职人员为样本，测量 AI 生成廉政微视频、互动式警示游戏及个性化廉洁提醒三类产品在情感共鸣度、信息记忆度、行为意向改变等指标上的效果。规范部分依据《生成式人工智能服务管理暂行办法》《中华人民共和国个人信息保护法》（以下简称《个人信息保护法》）等法规，对意识形态安全、虚假信息、数据隐私、责任归属四类风险进行法律分析[1][2]。

研究发现：三类 AIGC 产品在风险感知唤醒方面均显著优于传统图文材料，个性化提醒的感知精准度与提醒明确度呈正相关，验证了助推理论“越具体越有效”的核心命题。同时，研究界定了四道法律红线：开发者负有数据合规审查义务，服务提供者须强制标识 AI 生成内容，个人信息处理应恪守最小必要原则，责任认定以“控制力”为核心适用过错责任原则。研究表明，AIGC 可以成为唤醒风险感知的有效工具，但技术赋能必须审慎划定法律边界，三类产品各有其内在局限需针对性规制。

关键词：生成式人工智能，反腐败宣传教育，助推理论，法律伦理边界

Abstract

The rapid advancement of generative artificial intelligence (AIGC) has created new technological possibilities for anti-corruption education. However, the core challenge in building a culture of integrity remains how to extend the concept from 'daring not to be corrupt' and 'unable to be corrupt' to 'unwilling to be corrupt'. This study explores the application effects of AIGC in integrity education and its legal and ethical boundaries, aiming to provide dual support—technological empowerment and regulatory safeguards—for the development of integrity culture in the new era.

The study develops a four-dimensional analytical framework encompassing "technology empowerment, effectiveness evaluation, risk identification, and boundary regulation," integrating empirical research with normative analysis. The empirical component employs A/B testing with a sample of 100 public officials to assess the impact of three AI-generated products — integrity micro-videos, interactive warning games, and personalized integrity reminders — on emotional resonance, information retention, and behavioral change. The normative component conducts legal analysis of four risk categories (ideological security, misinformation, data privacy, and liability attribution) in compliance with regulations such as the "Interim Measures for the Administration of Generative AI Services" and the "Personal Information Protection Law."

The study reveals that three categories of AIGC products significantly outperform traditional text and image materials in triggering risk awareness. The accuracy of personalized reminders correlates positively with their clarity, validating the theory's core proposition that "the more specific, the more effective." Furthermore, the research establishes four legal red lines: developers must conduct data compliance reviews, service providers are required to mandate AI-generated content labeling, personal information processing should adhere to the least necessary principle, and liability determination should center on "control power" under the fault liability principle. The findings demonstrate that AIGC can serve as an effective tool for risk awareness, but technological empowerment must carefully define legal boundaries, with each product category requiring targeted regulation due to inherent limitations.

The study ultimately reveals that what truly prevents people from 'corruption' is not the fear of technological advancement, but the deep-seated commitment to integrity and reverence for responsibility—this is the original aspiration that technology can never reach, yet must safeguard.

Key words: Generative Artificial Intelligence, Anti-Corruption Education and Propaganda, Boosting Theory, Legal and Ethical Boundaries

目录

摘要 3
Abstract 4
目录 5
（一）问题提出 8
（二）研究意义 8
（三）研究方法 8
（四）核心概念界定 8
（五）论文章节安排 9
二、文献综述与理论基础 9
（一）生成式人工智能在公共服务领域的应用研究 9
（二）反腐败宣传教育的效果评估研究 10
（三）理论基础 10
2.3.1 助推理论 10
2.3.2 技术接受模型 10
2.3.3 法律伦理规制理论 10
2.3.4 研究综述与本文切入点 10
三、AIGC 廉政教育产品的设计与实现 11
（一）AI 生成廉政微视频 11
3.1.1 产品设计 11
3.1.2 技术实现路径 11
3.1.3 内在风险与局限 11
（二）互动式警示教育小游戏 11
3.2.1 产品设计 11
3.2.2 技术实现路径 12
3.2.3 内在风险与局限 12
（三）AI 个性化廉洁提醒 12
3.3.1 产品设计 12
3.3.2 技术实现路径 12

3.3.3 内在风险与局限 13
四、传播效果实证评估 13
（一）研究设计 13
4.1.1 实验对象与样本 13
4.1.2 实验刺激材料 13
4.1.3 实验程序 14
（二） 变量测量 14
4.2.1 因变量操作化定义 14
4.2.2 控制变量测量 14
（三）数据分析结果 15
4.3.1 信度与描述性统计 15
4.3.2 不同产品形式的差异化效果评估 15
（四）结果讨论 16
4.4.1 AIGC 的有效性与边界 16
4.4.2 局限性 17
五、法律与伦理边界 17
（一）意识形态安全风险 17
5.1.1 风险样态：算法偏见与价值观偏移 17
5.1.2 法律边界的界定 18
（二）虚假信息：当“廉政典型”被虚构 18
5.2.1 风险样态：深度伪造与信任危机 18
5.2.2 法律边界的界定 18
（三）数据隐私：个性化提醒的权利边界 18
5.3.1 风险样态：精准触达与过度收集 18
5.3.2 法律边界的界定 19
（四）责任归属：AI“犯错”谁担责链条 19
5.4.1 责任认定的复杂性 19
5.4.2 归责原则的思考 20
（五） 本章小结 20
六、制度回应与实践思路 21

（一） 针对意识形态安全风险：建立“数据过滤+人工审核”双重防线 21
（二）针对虚假信息风险：落实“显式标识+隐式追溯”强制性义务 21
（三）针对数据隐私风险：恪守“最小必要+分级分类”保护原则 21
（四） 针对责任归属风险：明确“以控制力”为核心的归责框架 22
（五）本章小结 ..... 错误！未定义书签。
结论 22
（一）研究总结 22
（二）理论贡献与实践意义 23
（三）研究局限与展望 23
（四）最终追问 23
参考文献 22

一、绪论

（一）问题提出

“不敢腐、不能腐、不想腐”是新时代反腐斗争的三重目标。持续高压反腐下，“不敢腐”的震慑效应已基本形成，“不能腐”的刚性约束正加速落地。然而，不想腐的思想自觉尚未完全扎根，部分干部仍存侥幸心理，理想信念滑坡、价值观扭曲问题尚未根本扭转，尤其在基层微权力运行中，人情干扰与认知惰性交织，导致廉政教育流于形式、警示教育震慑不足。如何让廉政意识真正内化于心、外化于行，成为新时代廉政建设必须突破的关键命题。本研究聚焦 AIGC 在廉政教育中的应用，探讨三个问题：第一，AIGC 产品如何设计才能有效唤醒风险意识？第二，相较于传统教育，其传播效果是否存在显著优势？第三，技术赋能伴随哪些法律伦理风险，其边界如何界定？

（二）研究意义

本研究将助推理论引入廉政教育领域，通过 A/B 测试验证了个性化信息干预在风险感知唤醒中的适用性[3]；同时从法学与传播学交叉视角构建了“技术赋能—效果评估—风险识别—边界规制”四维框架，为 AIGC 在公共治理领域的应用提供了分析工具。实践层面，三类产品的开发与测试为廉政教育数字化转型提供了可复制的经验，所揭示的法律风险可为纪检监察机关引入 AIGC 技术提供合规指引，加速教育沉浸式转型。

（三）研究方法

本研究综合运用实证研究与规范分析：实证部分采用 A/B 测试（样本量约 100 人），通过问卷调查测量三类产品在情感共鸣度、信息记忆度、行为意向改变等指标上的效果；规范部分依据《生成式人工智能服务管理暂行办法》等法规及司法裁判，对意识形态安全、虚假信息、数据隐私、责任归属四类风险进行法律分析。

（四）核心概念界定

生成式人工智能（AIGC），指基于算法、模型生成文本、图片、音频、视频等内容的技术[4]。本研究聚焦其在廉政教育内容生成中的应用，包括文本生成、图像视频生成、程序搭建三类形态。

反腐败宣传教育，指以公职人员为主要对象，以廉洁从政为核心内容的教育活动[5]。本研究聚焦“不想腐”层面的预防性教育，旨在通过唤醒风险感知，增强公职人员对腐败行为的自觉抵制意识。

（五）论文章节安排

全文共七章。第一章绪论，提出问题、界定概念并明确方法；第二章文献综述，梳理 AIGC 应用、廉政教育评估及理论基础研究，指出缺口并构建分析框架；第三章设计三类 AIGC 产品，阐明实现路径与内在局限；第四章效果评估，通过 A/B 测试验证三类产品传播效果并分析有效性边界；第五章风险识别，分析四样态风险并界定法律红线；第六章制度回应，针对四类风险提出规制建议；第七章结论，概括研究发现、点明理论贡献并指出研究局限。

二、文献综述与理论基础

本章旨在梳理相关领域的研究现状，明确理论基础，并在此基础上提出本文的分析框架。

（一）生成式人工智能在公共服务领域的应用研究

近年来，AIGC 技术迅速渗透公共服务领域，为政策解读、宣传教育等提供新手段。一些省市已自发探索 AIGC 赋能党纪教育实践，如郑州党纪教育课堂用 Deepseek 大模型构建“郑小纪 AI 互动学习平台”，供党员干部一键查看匹配案例，实现党纪法规的即时问答与个性化学习[6]；云南省纪委推出“清云”大模型，可辅助案件定性、分析廉洁风险等[7]。总体而言，AIGC 在宣传教育领域应用有三大特征：一是内容生成智能化，可快速产出多种廉洁文化产品；二是传播精准化，能根据受众特征推送定制内容；三是交互沉浸化，通过模拟现实等技术营造身临其境体验。

（二）反腐败宣传教育的效果评估研究

传统廉政教育效果评估主要采用问卷调查、访谈、知识测试等方法。在助推理论研究中，情境问卷测量被广泛用于评估干预效果[8]。本研究采用情境模拟实验+问卷调查的方法，沿袭这一研究传统，测量受众对个性化提醒的“感知精准度”“风险唤醒度”等核心变量。

（三）理论基础

2.3.1 助推理论

Sunstein 提出，行为干预的成功取决于干预信息在目标人群认知中能否“可激活”，越具体描述越容易激活[9][10]。个性化廉洁提醒正是基于此，通过岗位画像、风险场景描述唤醒风险感知，促使他们主动规避腐败行为。根据助推理论，提醒明确度越高，风险感知越强，行为改变可能性越大。本文将基于此与传统宣传教育对比并测量效果差异。

2.3.2 技术接受模型

Davis 提出，感知有用性和感知易用性是决定用户接受意愿的两个核心变量[11]。本文的 A/B 测试据此测量公职人员对 AIGC 廉政教育产品的接受度，包括感知有用性、感知易用性等核心指标，为问卷设计提供理论依据。

2.3.3 法律伦理规制理论

生成式人工智能的伦理风险与法律规制已成为关注焦点。雷磊指出，AI 无法进行真正的价值判断，本质是“根据输入值预测输出值”，只能“复述”而非“理解”，应坚持“辅助性定位”，最终责任由人类承担[12]。刘国胜、刘茗提出“技术逻辑—伦理冲突—治理响应”框架，强调通过动态法律嵌入、生成文本偏见审计等路径确保 AI 合规可控[13]。《生成式人工智能服务管理暂行办法》《人工智能生成合成内容标识办法》等明确了内容生产者责任和标识追溯要求[1][14]。上述理论为第五章风险识别与第六章的规制建议提供了分析工具。

2.3.4 研究综述与本文切入点

综上所述，学界对 AIGC 在党纪教育领域的应用已有初步探索，在技术赋能、效率提升方面积累了丰富案例，对 AIGC 应用的风险预见与法律规制也达成一定共识。但现有研究存在三个明显不足：一是应用场景局限于“不敢腐”“不能腐”层面，对“不想腐”的预防性教育关注不足；二是缺乏实证研究，AIGC 廉政产品的有效性及受众效果差异需实验验证；三是法律伦理边界不清晰，如个性化提醒的“精确度”与“隐私保

护”平衡问题，亟须理论探讨与制度完善。

基于这些缺口，本文构建“技术赋能——效果评估——风险识别——边界规制”四维框架，通过 A/B 测试验证效果，在研发与应用中识别风险、界定法律红线，为廉洁文化建设提供双重支撑。

三、AIGC 廉政教育产品的设计与实现

（一）AI 生成廉政微视频

3.1.1 产品设计

传统廉政教育微视频制作周期长、成本高，难以实现“一人一片”精准供给。AIGC 的成熟使快速生成岗位定制化视频成为可能。本团队采用“文本+图像+数字人”多模态工作流，设计以《茶凉之前》为主题、法律为内核的廉政微视频。剧本以亲戚请托为切入点，借茶从滚烫到微凉隐喻权力边界在人情中失守，梦中醒悟与现实入狱的反差强化了“慎初、慎微、慎独”警示张力。

3.1.2 技术实现路径

本团队首先用 DeepSeek 生成脚本，提示词含岗位类型、风险场景、价值导向（须符合“全面从严治党要求”）三要素。经人工审核后，依据脚本让 DeepSeek 提供生成关键帧的提示词，交由即梦文生图生成画面图片。随后，通过图生视频功能转化为分镜头，选取人物说话镜头导入即梦对口型处理。接着将多段素材导入剪映剪辑，由数字人驱动完成语音合成与表情同步，并添加实时字幕、音频和音效。最后加设开头与结尾，全程嵌入人工审核节点，形成完整叙事闭环。这一闭环验证了 AIGC 多模态技术在廉政教育场景的可行性，构建起“政策—文本—图像—语音—行为”的全链条合规生成范式。

3.1.3 内在风险与局限

局限体现在三个方面：一是视频人物生动性受技术水平限制，表情有细微偏离；二是所选岗位单一，后期优化将拓展至高风险岗位，并动态接入各地最新典型案例，实现警示教育内容实时迭代与靶向推送；三是 AI 实际运用存在提示词不准确、分镜生成有偏差、数字人微表情与语义节奏偶有脱节等问题，上手门槛较高。

（二）互动式警示教育小游戏

3.2.1 产品设计

《人民的名义》因反腐斗争与人性抉择的叙事张力而广泛传播，本团队据此提炼“小

人物的大是非”的核心主题，并转化为 12 个生活化决策场景，设计三选项决策机制与“生存指数—风险指数—良心指数”三轨数值反馈系统。三指数实时联动，每次决策后生成经人工复核的道德指引与法律分析，标注选择对三项指数的边际影响。数值变化决定游戏走向，包括“平安是福”（风险指数≤1，良心指数≥8）、“深渊回望”（风险指数≥8 或累计三次严重错误选项）、特殊结局（累计四次及以上严重错误选项）和默认结局“普通人生”（未触发上述情况）。游戏设计旨在强化道德选择认知，减少抽象说教的空泛性，提升基层干部在灰色地带的判断敏感度与行为定力。

3.2.2 技术实现路径

我们采取“大模型带专常模型”策略，由 AI agent 向子模型发送自然语言指令，逻辑强的模型用于设计，有专长的模型做具体工作。先将产品设计构想输入 AI 系统，生成游戏剧本并评估其设计合理性、可读性和价值导向正确性。同时，生成媒体素材所需的 prompt，将其作为图像处理专长模型的提示词生成相关素材。接着，用 Vibecoding 专长模型搭建产品框架，编写 JavaScript 实现动画交互。最后整合嵌入 HTML 文件，方便浏览器打开，提升跨平台兼容性与部署效率，降低开发成本和产品流通性。

3.2.3 内在风险与局限

局限体现在四个方面：一、作品未覆盖基层、高层干部高频接触的权力场景；二、AI 检索法条可能存在用语不精确或错误诱导；三、AI 指令理解有语义偏差，在配色方案、视觉隐喻等抽象指令上，模型常陷入字面解码而失去教育意图；四、编码模型缺乏版本控制能力，使 HTML 与 JavaScript 代码迭代时，难以追溯修改痕迹、复现问题场景，亦无法支撑多人协同开发，放大维护成本与更新风险。

（三）AI 个性化廉洁提醒

3.3.1 产品设计

过往廉政教育存在三方面问题：一是内容同质化严重，难以匹配不同岗位、职级干部的实际需求；二是形式静态单一，缺乏互动性与代入感；三是风险预警滞后，未能动态感知与前置干预苗头性问题。本团队引入“个性化提醒文案+案例匹配”思路，融合个体特征、岗位职责、真实案例及行为数据，构建廉政画像，实现精准推送、情景模拟与风险预判。系统采用网页交互方式，用户选择基础身份信息、行为偏好与工作场景后，即可完成画像匹配与文案生成，输出含风险提示、正向引导与同类型案例参照的三段式提醒文本。

3.3.2 技术实现路径

构建网页前，团队预先调研腐败案例，分析关键影响因素（岗位、年龄、任职经验

及个性特征），进而基于各种组合评估风险等级，构建用户画像。接着，用生成式 AI 编辑积极引导的个性化文案，兼具情感温度与场景化体验。同时，利用 AI 工具整合纪委监委官网关键信息，检索腐败案例并依据组合分类，实现精准投放。为保证权威性与合规性，输出的文案与案例都经人工复核。

3.3.3 内在风险与局限

主要体现在四个方面：一、本系统收集用户选项构建画像，在文案库中匹配提醒文案与案例，本质是静态检索与信息匹配，缺乏智能互动。二、系统按用户个性四维度量化风险值，模型简单，后期可收集案例数据分类统计，利用回归模型构建风险级别量化函数，建立更加科学的风险评估模型。三、因用户个性和岗位复杂多样，系统选项只能构建简单画像，后期可细分岗位和个性特征，精确用户画像。四、团队在 AI 应用中发现文案重复、代码遗失、颜色判断失误等问题。

四、传播效果实证评估

本章通过 A/B 测试实验，实证评估 AIGC 技术在不同廉政教育产品中的应用效果，比较其与传统图文形式在廉洁意识唤醒度、信息记忆留存度和行为意向改变三个维度上的差异，并探讨控制变量的影响。

（一）研究设计

4.1.1 实验对象与样本

本研究与某市纪委监委合作，在该市党政机关、事业单位及国有企业中招募公职人员参与实验。采用随机抽样方式，共招募有效样本 100 人。样本的基本人口学特征分布如图 4-1 所示。

图 4-1　样本人口统计学特征分布（N=100）

4.1.2 实验刺激材料

被试分别接触不同类型的廉政教育内容，时长/交互时间控制在 5-8 分钟：

表 1　对比实验表

对照组	传统图文
实验组 A	AI 生成微视频
实验组 B	互动式警示教育游戏
实验组 C	个性化廉洁提醒

4.1.3 实验程序

实验在线上进行。被试分别接受不同宣传材料，干预结束后，立即填写电子问卷。整个过程约 30 分钟，包括知情同意、干预和问卷填写。问卷采用匿名方式，仅收集人口学信息和实验相关变量。

（二） 变量测量

4.2.1 因变量操作化定义

本研究设置三个核心因变量，均通过问卷测量。每个核心因变量均采用 5 个题项测量，并采用李克特 5 点量表（1=非常不同意，5=非常同意），取 5 题均值为最终得分。题项如下：

(1)信息记忆留存度：“我能清晰回忆起宣传产品中的关键内容”“本次宣传中的真实案例/情节给我留下深刻印象”“我能准确记住本次宣传传递的廉政要求”“相比以往宣传，本次内容更容易被记住”“我认为本次宣传会在长时间内影响我”。

(2)廉洁意识唤醒度：“本次宣传让我更加清醒认识到廉洁自律的重要性”“本次内容激发了我对廉洁从政的内在认同”“完成后我对岗位廉洁风险的警惕性提升”“本次宣传强化了我对腐败行为的排斥心理”“本次内容让我产生了强烈的廉洁自律意识”。

(3)行为意向改变：“未来我会更加主动遵守廉洁纪律规定”“我会在工作中主动规避可能的廉政风险”“面对诱惑时，我更有底气拒绝不当利益”“我愿意向身边同事传递本次学到的理念”“本次宣传会切实影响我未来的工作行为”。

4.2.2 控制变量测量

为排除个体差异对效果的干扰，收集以下控制变量：

年龄：分类变量，分为 30 岁及以下、31-40 岁、41-50 岁、51 岁及以上。

岗位类型：分类变量，分为基层一线岗、综合行政岗、执法监督岗、审批服务岗、

其他。

过往廉政教育频率：分类变量，分为每年一次及以下、每半年一次、每季度一次、每月一次及以上。

（三）数据分析结果

4.3.1 信度与描述性统计

首先对量表进行信度检验。信息记忆留存的 Cronbach's α系数为 0.944，廉洁意识唤醒度的α系数为 0.959，行为意向改变的α系数为 0.988，均大于 0.9，表明量表信度良好。

各组在三个因变量上的描述性统计结果如表 2 所示。从均值看，三个 AIGC 实验组在廉洁意识唤醒度和行为意向改变上均高于对照组，其中实验组 B（互动游戏）的得分最高；信息记忆留存度方面，各组均值较为接近，实验组 C（个性化提醒）略高。

表 2　各组在三个因变量上的描述性统计（M±SD）

组别	信息记忆留存度	廉洁意识唤醒度	行为意向改变
对照组	4.19±0.674	4.206±0.679	4.246±0.675
实验组 A（视频）	4.242±0.923	4.418±0.638	4.352±0.951
实验组 B（游戏）	4.312±0.569	4.416±0.584	4.488±0.524
实验组 C（提醒）	4.186±0.623	4.334±0.946	4.564±0.568

4.3.2 不同产品形式的差异化效果评估

采用单因素方差分析（One-Way ANOVA）检验四组在三个因变量上是否存在显著差异。首先进行方差齐性检验（Levene 检验），三个因变量的 p 值均小于 0.05，不满足方差齐性假设，采用 Welch's 方差检验。

表 3 单因素方差分析结果

变量名	变量值	样本量	平均值	标准差	方差检验	Welch's 方差检验
信息记忆留存度	A	100	4.242	0.923	F=0.683 P=0.563	F=0.955 P=0.415
	B	100	4.312	0.569		
	C	100	4.186	0.623		
	对照组	100	4.19	0.674		
	总计	400	4.233	0.709		
廉洁意识唤醒度	A	100	4.418	0.638	F=1.888 P=0.131	F=2.296 P=0.079
	B	100	4.416	0.584		

	C	100	4.334	0.946		
	对照组	100	4.206	0.679		
	总计	400	4.344	0.728		
行为意向改变	A	100	4.352	0.951	F=4.089 P=0.007	F=4.872 P=0.003
	B	100	4.488	0.524		
	C	100	4.564	0.568		
	对照组	100	4.246	0.675		
	总计	400	4.412	0.708		

结果显示，A 与 B 与 C 与对照组在信息记忆留存度上，方差分析结果 P 值为 0.415>0.05，因此统计结果不显著，说明不同的组别在信息记忆留存度上不存在显著差异。

A 与 B 与 C 与对照组在廉洁意识唤醒度上，方差分析结果 P 值为 0.079>0.05，因此统计结果不显著，说明不同的组别在廉洁意识唤醒度上不存在显著差异。

A 与 B 与 C 与对照组在行为意向改变上，方差分析结果 P 值为 0.003≤0.05，因此统计结果显著，说明不同的组别在行为意向改变上存在显著差异。

进一步进行事后多重比较（LSD 法），结果如下：

使用 LSD 方法的事后多重比较的结果显示：

对于变量信息记忆留存度，均值大小排序为：B>A>对照组>C。总体均值都不存在显著性差异。

对于变量廉洁意识唤醒度，均值大小排序为：A>B>C>对照组。其中 A 与对照组、B 与对照组存在显著性差异。

对于变量行为意向改变，均值大小排序为：C>B>A>对照组。其中 A 与 C、B 与对照组、C 与对照组存在显著性差异。

（四）结果讨论

4.4.1 AIGC 的有效性与边界

实验结果表明，AIGC 技术在廉政教育中展现出显著优势：

（1）相比传统图文，AIGC 产品提高了公职人员的信息记忆留存度、廉洁意识唤醒度和行为意向改变。这一结果验证了助推理论在廉政领域的适用性：通过沉浸式叙事和交互设计，非强制性的行为干预能够有效触动情感、激发内在动机。

（2）在信息记忆留存度上，微视频和互动游戏表现显著优于对照组，个性化提醒与对照组无明显差异。这可能是因为动画形式和情境体验相比图片和文字对记忆促进作用

更强。

（3）在廉洁意识唤醒度上，三种产品表现均优于对照组。这表明沉浸式的情境体验和个性化的定向宣传在情感唤醒上效果突出。

（4）在行为意向改变上，个性化提醒表现最佳，互动游戏次之，微视频第三，均高于对照组。这表明个性化的行为指导在廉政教育中起到关键作用。

4.4.2 局限性

本研究存在以下局限：样本仅来自单一城市，代表性有限；效果测量为即时后测，缺乏长期追踪；实验环境与真实学习环境存在差异。未来可扩大样本范围，开展纵向研究，并引入眼动、皮电等生理指标深化效果测量。

五、法律与伦理边界

杜治洲指出，人工智能嵌入廉政治理引发的多种伦理风险，遵循“内生集聚——衍生增强——传导扩散——后果生成”复杂路径[15]。承接第四章的实证发现，本章聚焦AIGC 赋能廉政教育的四类法律伦理风险并依据现行法律界定其边界。

（一）意识形态安全风险

5.1.1 风险样态：算法偏见与价值观偏移

廉政教育具有鲜明的政治与意识形态属性，AIGC 生成内容是否契合社会主义核心价值观、准确传达党纪法律，关系廉政教育政治与价值导向。实践中，AIGC 可能因训练数据偏差、提示词引导失当等，生成淡化政治属性、弱化纪律刚性、隐含错误价值取向的内容。牛子牛指出，AIGC 意识形态倾向受互联网舆论生态决定性影响[16]。生成式人工智能预训练阶段无差别抓取海量数据，输出在廉政教育场景中易被误认为“客观陈述”，消解了党纪国法的严肃性与政治话语的规范性。此时，算法不再是纯粹的技术工具，而可能成为价值传导的节点。

具体而言，意识形态安全风险有以下样态：一是价值观偏移，模型可能输出与主流意识形态相悖内容，如美化违规违纪行为；二是政治表述错误，对政策方针等专业内容表述出现偏差；三是形象污名化风险，AI 生成公职人员形象时受数据中负面刻板印象影响，强化公众负面认知。这些内容一旦进入教育场景，将侵蚀廉政教育思想根基，削弱其意识形态引领力。牛子牛警示，将特定技术路线当作“技术本身”是一种“技术拜物教”观念[17]。

5.1.2 法律边界的界定

《生成式人工智能服务管理暂行办法》第四条将“坚持社会主义核心价值观”确立为法律义务，要求服务提供者承担筛选责任，从数据源头上剔除含意识形态偏差、错误政治表述的训练数据，确保预训练语料库政治纯洁性与价值导向性[1]。第七条规定，服务提供者应采取有效措施提高训练数据质量，增强其真实性、准确性、客观性、多样性[1]。因此，开发者负有数据合规审查义务，不能以“技术中立”推卸责任。

（二）虚假信息：当“廉政典型”被虚构

5.2.1 风险样态：深度伪造与信任危机

AIGC 的核心能力是“无中生有”，即在无真实依据前提下生成高度逼真的文本、图像、音视频内容，正如 Zeide 认为，生成式人工智能能够生成超真实但完全虚构的内容，以前所未有的规模塑造公共话语[18]。

这一能力在廉政治理中极易异化为“典型造假”：虚构清廉楷模、捏造反腐案例、伪造权威部门发布的警示教育材料等。此类深度伪造内容不仅破坏信息真实性根基，更在公众认知中构建起虚假的廉政叙事闭环，诱发“劣币驱逐良币”的信任塌方。当公众知情权被侵害，难以区别“真典型”与“假模范”时，廉政治理的合法性基础轰然倒塌。

同时，杨智冰、王思懿指出，AI 深度合成技术发展迅猛，使大众能够以极低的时间和金钱成本定制视频生成[19]。技术的普适性降低了生成门槛，一方面伪造音视频侵权现象日趋严重，引发法律纠纷；一方面作品质量良莠不齐，缺乏有效监管与审核机制。部分作品为博取播放量而刻意放大猎奇性，将廉政宣传过度娱乐化，既消解了廉政教育本身的严肃性定位，又在公众认知中不断植根负面刻板印象。

5.2.2 法律边界的界定

深度合成技术的滥用风险，印证了 AIGC 廉政产品绝非价值无涉的工具。现行《生成式人工智能服务管理暂行办法》第十二条明确要求“提供者应当采取技术措施和其他必要措施，防止生成虚假信息”[1]。同时《互联网信息服务深度合成管理规定》明确要求：深度合成服务提供者应当在生成或者编辑的信息内容的合理位置、区域进行显著标识，向公众提示深度合成情况[20]。

（三）数据隐私：个性化提醒的权利边界

5.3.1 风险样态：精准触达与过度收集

个性化廉洁提醒是 AIGC 在廉政教育中的重要应用场景，其核心优势在于“精确”：依据公职人员的岗位类型、过往行为轨迹、性格偏好等精确画像，生成“千人千面”的

针对性提醒。然而，精准触达依赖于个人数据的深度挖掘。杨培泽、金明浩指出，在训练数据的处理和使用过程存在着算法偏见、信息泄露、数据歧视和侵犯知识产权等风险[21]。而具体到廉政教育场景：

第一、过度收集个人信息。AIGC 廉政产品在干部廉政画像、风险预警等场景，常以“个性化提醒”为名，过度采集社交关系、消费习惯、网络言论等非必要敏感信息，存在突破《个人信息保护法》第二十八条“特定目的+充分必要+单独同意”的风险[2]。同时，该法指出，处理已公开且对个人权益有重大影响的个人信息，应依法取得个人同意，处理敏感个人信息须取得单独同意。杜治洲指出：“在追求廉政监督精准性的过程中，必须警惕技术应用对个体基本权利的侵蚀。监督权的扩张与技术赋能，不应以牺牲个体的隐私权、人格尊严为代价[15]。”

第二，岗位画像的标签性歧视。AIGC 因训练数据偏差，可能会对特定地域、职级或群体系统性误判，形成对特定岗位人员的群体性偏见，侵犯其人格尊严和平等权。过度依赖算法画像代替实际考察，不仅增加纪检人员懒政怠政风险，而且当廉洁提醒沦为行为预测，监督逻辑便从“防微杜渐”变为“未罪先判”。正如牛子牛警示，技术治理精准化追求有内在风险，对“可能性”的干预可能逾越“现实性”规制边界，缺乏伦理约束的行为干预，将在无形中消解法治底线[17]。

第三，数据泄露风险。廉政教育系统存储大量公职人员敏感信息，面临黑客攻击和内部人员泄露风险，敏感信息一旦泄露，可能引发不法分子精准勒索、政治攻击等连锁行为。

5.3.2 法律边界的界定

《个人信息保护法》第六条明确要求“处理个人信息应当具有明确、合理的目的，并应当与处理目的直接相关”，廉政教育中的数据采集必须严守“最小必要”原则。同时，《互联网信息服务算法推荐管理规定》要求算法推荐服务提供者加强用户模型和用户标签管理，不得将违法和不良信息关键词计入用户兴趣点或者作为用户标签[22]。这一规定同样适用于廉政教育中的风险标签管理——不得将“可能有问题”主观推断固化为算法标签，避免造成群体性偏见。

5.4.1 责任认定的复杂性

在现行法律框架下，AIGC 廉政产品失当输出难以简单归责于单一主体。张海燕指出，AI 生成谣言的侵权行为可能由算法倾向、吸收数据、人机交互等因素共同或单独引发，而难以确定直接因果关系，导致责任主体确定陷入困境[23]。传统侵权责任基于“行

为人——行为——后果”的清晰链条，但 AIGC 的介入使该链条变得模糊。

第一，开发者责任边界模糊。受大模型发展水平限制，开发者无法保证生成内容完全可控，“知道”或“应当知道”的义务来源难以解释，认定过错与因果关系较困难。

第二，使用者责任认定困境。纪委监委作为使用单位，工作人员仅输入提示词、点击选项生成内容，未直接编写错误内容，认定其为“侵权行为人”难以成立。

第三，人机混合决策的归责难题。如工作人员审核修改 AI 生成内容后仍保留部分错误内容，责任比例该如何划分？

（四）责任归属：AI“犯错”谁担责链条

5.4.2 法律边界的界定

一、在服务提供者的责任承担与注意义务上，有观点主张过错推定原则以平衡举证义务分配，亦有观点坚持一般过错责任原则的普适性。但杭州互联网法院在审理全国首例生成式 AI“幻觉”侵权案时已明确，生成式人工智能属于“服务”范畴，应适用《中华人民共和国民法典》第一千一百六十五条第一款的一般过错责任原则[24][25]。同时，法院采用动态系统论阐述了服务提供者的三层注意义务：第一，对违法信息的严格审查义务；第二，以显著方式提示生成内容可能不准确的局限性；第三，采取同行业通行技术措施提高内容准确性的基本注意义务。

二、在用户责任上，张海燕指出，AI 用户作为谣言直接传播者，是事后救济关键角色[23]。人机协同创作时，AI 用户应批判性使用技术。利用 AI 进行信息生成与扩散，因过失未防范可预见伤害的，依损害后果、严重程度担责。对故意实施的违法行为，尤其是蓄意编造传播虚假消息的，司法机关在刑法适用中降低入罪门槛、从重规制，在民法适用中适当提高赔偿和罚款金额。

（五） 本章小结

AIGC 赋能反腐宣传教育，面临四道不可逾越的法律红线：第一，意识形态安全红线要求生成内容必须坚持社会主义核心价值观，开发者负有数据合规审查义务；第二，虚假信息红线要求强制标识 AI 生成内容，防范公众不当信赖；第三，数据隐私红线要求恪守最小必要原则，敏感信息处理须获单独同意；第四，责任归属红线明确 AI 不具有民事主体资格，服务提供者承担过错责任。这些红线共同构成了 AIGC 赋能廉政教育的法律边界。

六、制度回应与实践思路

针对第五章识别的四类风险，本章从制度嵌入、规范供给、标识追溯、责任界定四个维度，提出对应的规制建议，构建“向善规范的 AI 廉政教育体系”。

（一） 针对意识形态安全风险：建立“数据过滤+人工审核”双重防线

意识形态安全风险根源在于算法的“无意识强化”，并非源于开发者主观恶意，而是训练数据的结构性偏见、提示过程中政治价值观把关缺位、AI 价值判断能力缺失三重因素叠加所致。

对此，需从输入端和输出端共同发力：输入端需以中纪委发布的权威表述库、案例库为参考，对训练数据中涉廉表述进行政治性前置筛查，剔除含有错误表述或负面刻板印象的数据源。在实践创新中，可先行试点将社会主义核心价值观、党纪处分条例等抽象价值要求，转化为可嵌入算法训练的量化指标的体系化建设[26][27]。在输出端，推动建立“AI 生成+人工审核”的双重机制，对生成内容中关键政治术语、历史事件与人物评价设置不可绕过的价值观校验、关键词拦截等程序，经纪委人工复核后方可发布。

（二）针对虚假信息风险：落实“显式标识+隐式追溯”强制性义务

防范虚假信息风险，关键在于让受众知晓内容“AI 生成”属性，并实现生成过程可追溯。依据《网络安全技术 人工智能生成合成内容标识方法》显式标识上，所有 AI 生成的廉政教育内容应在显著位置标注“本内容由 AI 生成”“虚拟人物，请勿模仿”等字样，保障群众知情权[28]；隐式追溯上，在文件元数据中嵌入生成时间、模型版本、关键提示词等信息，便于争议发生时技术溯源[28]。实践中，可通过建立人机协同的决策日志留痕与回溯，依据日志记录查漏补缺，倒逼算法优化与人员培训提升[1][2][23][24][29]。

（三）针对数据隐私风险：恪守“最小必要+分级分类”保护原则

个性化提醒的精准触达与个人隐私保护存在天然张力，防控张力扩大核心是精准界定廉政教育场景数据处理边界。数据采集应遵循“最小必要”原则，仅采集岗位类别、职级层级等与廉政教育效果直接相关的信息，禁止收集生物识别、家庭关系等敏感信息[2][30]；数据存储与使用按风险等级分级分类管理，高敏感数据加密隔离、授权访问并定期开展隐私影响评估，低敏感数据脱敏处理后接入模型训练，公开数据直接用于通用分析[31]。此外，建立数据全生命周期审计机制，对各环节动态监控与合规校验[32]；加强员工数据安全意识培训，并纳入考核内容，提升风险意识与操作能力。

技术理性与制度伦理并非非此即彼的命题，而是要以敬畏之心在效率边界刻下不可逾越的红线——每一份精准提醒背后都矗立着对人格尊严的庄严承诺，每一次模型升级都要以数据保护为前提。

（四） 针对责任归属风险：明确“以控制力”为核心的归责框架

责任归属困境的破除不能仅靠司法的判决，应从源头厘清人机协同中的实际控制力边界。

技术端推动人机协同日志的强制化留痕与定期回溯，确保生成过程有由提示词输入、算法响应、人工干预及终审确认的完整证据链，为责任的比例划分提供客观依据[14][33]。这不仅有利于厘清技术失当与人为失职的边界，在纠纷发生时快速锁定关键责任节点，更有利于抓住算法全链条的可干预节点，实现事前风险防控的闭环。唯有如此，方能在责任切割中辨明技术黑箱内的介入深度，破除“工具无罪”的认知迷思。

司法端需突破“谁使用，谁负责”的简单归责逻辑，应依据风险发生阶段划分责任主体：训练阶段，开发者承担数据合规与价值观对齐义务；部署阶段，平台方履行提示词治理与输出过滤责任；使用阶段，压实纪检监察机关的人工终审与结果追责权。

立法端应加快《纪检监察人工智能应用条例》立法进程，明确三阶段义务的法定化边界、举证责任倒置规则及连带责任触发条件，真正破除“技术中立”的制度幻觉，提升廉政 AI 法治化、规范化水平[33][34]。

结论

（一）研究总结

本研究围绕生成式人工智能在反腐败宣传教育中的应用，构建了“技术赋能—效果评估—风险识别—边界规制”的四维分析框架，综合运用实证研究与规范分析，得出以下主要结论：

研究表明，AIGC 廉政教育产品在提升风险感知方面具有显著效果。A/B 测试显示，三类产品在情感共鸣度、信息记忆度、行为意向改变等指标上均显著优于传统图文材料，个性化提醒的感知精准度与明确度呈正相关，验证了助推理论“越具体越有效”的核心命题[9][10]。然而技术赋能的有效性存在边界：微视频可能面临新颖性衰减，互动游戏可能产生认知负荷，个性化提醒可能引发信息过载。

同时，技术赋能伴随四重法律风险：意识形态安全风险源于训练数据偏见与 AI 价值判断缺失；虚假信息风险源于深度伪造技术对公信力的侵蚀；数据隐私风险源于精准触达与个人信息的张力；责任归属风险源于人机混合决策的归责困境。《生成式人工智能服务管理暂行办法》《个人信息保护法》等法规为四类风险划定了明确边界：开发者负有数据合规审查义务，服务提供者须强制标识 AI 生成内容，个人信息处理应恪守最小必要原则，责任认定以“控制力”为核心适用过错责任原则[1][2]。

（二）理论贡献与实践意义

理论层面，本研究将助推理论拓展至廉政教育研究，验证了个性化信息干预在风险感知唤醒中的适用性[9][10]；构建的四维分析框架为 AIGC 在公共治理领域的应用提供交叉学科的分析工具。

实践层面，剖析三类产品的内在局限得出：微视频的价值观对齐困境提示技术开发者必须将伦理审查嵌入产品设计全流程；互动游戏的隐私边界争议警示数据采集须恪守“最小必要”原则；个性化提醒的算法偏见风险要求建立定期审计机制。这些发现为纪检监察机关引入 AIGC 技术提供了可复制的经验。

（三）研究局限与展望

本研究存在三方面局限：一是受条件限制，A/B 测试参与者主要为基层公职人员，未能覆盖高层级领导干部；二是实验仅测量短期风险感知变化，未能追踪长期行为改变；三是 AIGC 技术日新月异，本研究的结论可能随技术发展而需调整。

未来研究可以从以下方向深化：一是引入多模态行为数据（如眼动追踪、生理指标）实现更精细化的效果评估；二是开发针对廉政教育的专用微调模型；三是跟踪法律政策的更新动态，结合人工智能立法进程完善规制框架。

（四）最终追问

行文至此，我们或许需要追问一个更根本的问题：当 AI 可以生成越来越逼真的警示画面，当算法可以推送越来越精准的风险提醒，廉政教育究竟在“教育”什么？

本研究给出的回答是：AI 可以成为工具，但不能成为主体；可以提供提醒，但不可以替代思考；可以模拟后果，但不能塑造价值。真正让人“不想腐”的，从来不是技术

制造的恐惧，而是内心深处对廉洁的认同与对责任的敬畏——而这，恰恰是技术永远无法抵达、却必须始终守护的初心。

参考文献

[1] 国家互联网信息办公室，国家发展和改革委员会，教育部，科学技术部，工业和信息化部，公安部，国家广播电视总局．生成式人工智能服务管理暂行办法[Z]. 2023-07-10.

[2] 全国人民代表大会常务委员会．中华人民共和国个人信息保护法[Z]. 2021-08-20.

[3] Thaler, R. H., & Sunstein, C. R. *Nudge: The Final Edition*[M]. New York: Penguin Books, 2021.

[4] 科普中国.生成式人工智能[EB/OL].2025-02-25.

[5] 马骁．新时代中国共产党廉政教育研究[D]．大连：辽宁师范大学，2018.

[6] 徐志强．新技术实现分类施教、精准警示[J]．中国纪检监察，2025，(23).

[7] 张驰．对战 AI 大模型，党规党纪精准学[EB/OL]．人民日报客户端，2025-07-29.

[8] Gandhi, L., et al. *Hypothetical nudges provide directional but noisy estimates of real behavior change*[J]. Communications Psychology, 2025, (3).

[9] Sunstein, C. R. *The availability heuristic, intuitive cost-benefit analysis, and climate change*[J]. *Climatic Change*, 2006, 77(1).

[10] Sunstein, C. R. Behavioral Science and Public Policy[M]. Cambridge: Cambridge University Press, 2020.

[11] Davis, F. D. *Perceived usefulness, perceived ease of use, and user acceptance of information technology*[J]. *MIS Quarterly*, 1989, 13(3).

[12] 雷磊．完美的效率还是负责任的正义？——大语言模型时代数字司法的价值反思[J]．东方法学，2025，(4).

[13] 刘国胜，刘茗．生成式人工智能司法应用的伦理困境与治理路径[J]．河北经贸大学学报(综合版)，2025，(3).

[14] 国家互联网信息办公室，工业和信息化部，公安部，国家广播电视总局．人工智能生成合成内容标识办法（国信办通字〔2025〕2 号）[Z]. 2025-03-07.

[15] 杜治洲，卢佳琦．人工智能嵌入廉政治理的伦理风险及其防范[J]．广州大学学报(社会科学版)，2024, 23(4).

[16] 牛子牛．生成式人工智能的意识形态风险与治理策略：基于政治经济学批判方法的考察[J]．人文杂志，2025，(1).

[17] 牛子牛．当代信息智能技术的本质与边界——基于政治经济学批判方法的考察[J]．哲学动态，2025，(8).

[18] Zeide, E. *The AI Censorship Edge*[J]. *University of Pennsylvania Journal of Constitutional Law,* 2023, 25(3).

[19] 杨智冰，王思懿. AI 深度合成技术——是“魔”是“仙”，多维度监管机制说了才算[EB/OL]. LEGALBAND, (2025-03-13).

[20] 国家互联网信息办公室，工业和信息化部，公安部．互联网信息服务深度合成管理规定（国家互联网信息办公室、中华人民共和国工业和信息化部、中华人民共和国公安部令第 12 号）[Z]. 2022-11-25.

[21] 杨培泽，金明浩．生成式人工智能训练数据的风险识别与治理对策[J]．武汉公安干部学院学报, 2025，(4).

[22] 国家互联网信息办公室，工业和信息化部，公安部，国家市场监督管理总局．互联网信息服务算法推荐管理规定（国家互联网信息办公室、中华人民共和国工业和信息化部、中华人民共和国公安部、国家市场监督管理总局令第 9 号）[Z]. 2021-12-31.

[23] 张海燕. “AI 生成谣言”的责任主体与归责原则[J]．法治时代, 2025，(9).

[24] 杭州互联网法院．梁某诉某科技公司网络侵权责任纠纷案一审判决书[Z].（2025）浙 0192 民初 XXX 号, 2025-12.

[25] 全国人民代表大会．中华人民共和国民法典[Z]. 2020-05-28.

[26] 朱萌，张权，赵璐．中国式现代化视阈下主流意识形态嵌入算法的机制与路径研究[M]．北京：社会科学文献出版社, 2025. (中国式现代化研究丛书)

[27] 陈世华，汤黎．构建“制度—产业—技术”三位一体治理体系[N]．中国新闻出版广电报, 2025-10-14.

[28] 国家市场监督管理总局，国家标准化管理委员会. GB 45438-2025 网络安全技术 人工智能生成合成内容标识方法[S]．北京：中国标准出版社, 2025.

[29] 梅维佳．加快推进生成式人工智能的规范化法治化[N]．武汉市委网信办, 2025-11-28.

[30] 中央网信办，国家发展改革委．政务领域人工智能大模型部署应用指引[Z]. 2025-10-11.

[31] 全国人民代表大会常务委员会．中华人民共和国数据安全法[Z]. 2021-06-10.

[32] 国家发展改革委，国家数据局，中央网信办，工业和信息化部，公安部，市场监管总局．关于完善数据流通安全

治理 更好促进数据要素市场化价值化的实施方案[Z]. 2024.
[33] 林洹民. 论人工智能致损的特殊侵权责任规则[J]. 上海交通大学学报(哲学社会科学版), 2025.（2）
[34] 杭州互联网法院. 梁某诉某科技公司网络侵权责任纠纷案一审判决书[Z].（2025）浙 0192 民初 XXX 号, 2025-12.